

Федеральное государственное бюджетное образовательное учреждение  
высшего образования  
«Новосибирский государственный технический университет»

Кафедра теоретической и прикладной информатики

## РАСЧЕТНО-ГРАФИЧЕСКОЕ ЗАДАНИЕ

по дисциплине «Статистический анализ нечисловых данных»

### **Работа с текстовыми данными. Интеллектуальный анализ текстов**

Направление подготовки: 02.03.03 Математическое обеспечение и администрирование информационных систем.

Выполнил:

Студент: Сидоров Д. И.

Группа: ПМИ-02

Факультет: ПМИ

\_\_\_\_\_

подпись

«\_\_» ноября 2023 г.

Проверил:

Преподаватель: Тимофеева А.Ю.

Балл: \_\_\_\_\_

Оценка \_\_\_\_\_

\_\_\_\_\_

подпись

«\_\_» ноября 2023 г.

Новосибирск, 2023

## **Оглавление**

Постановка задачи .....	3
Ход работы .....	3

## Постановка задачи

Вариант	Файл	word1	word2	t-test*	Chi2*	LHR*	MI*
26	text_sent_3	...	boosting	+	-	-	+

Исходный набор данных содержит текст учебника Berk R. A. Statistical learning from a regression perspective. – Switzerland: Springer, 2020. – 433 с. Для исходного текста выполнена предварительная обработка. Результат представлен в файле text\_sent\_3. Каждая строка соответствует одному предложению. Слово с апострофом считается как одно слово (например, “what’s”).

Необходимо проанализировать биграммы смежных слов (стоящие рядом в одном предложении).

## Ход работы

**1. Из всего текста отоберем комбинации смежных слов, содержащие слово “boosting” на второй позиции. На первой позиции может быть любое слово. Сразу проранжируем биграммы по частоте встречаемости и сделаем предварительные выводы о возможных коллокациях.**

Всего таких комбинаций в корпусе – 57. Построим таблицу, в которой в первых двух столбцах будут соответствующие слова из биграмм, а в остальных столбцах – абсолютные частоты, которые можно получить из таблицы сопряженности, имеющей в общем случае следующий вид:

	$y = w_2$	$y \neq w_2$
$x = w_1$	$O_{11}$	$O_{12}$
$x \neq w_1$	$O_{21}$	$O_{22}$

$O_{ij}$  – абсолютные частоты. Рассмотрим каждую частоту подробнее:

- $O_{11}$  – количество биграмм  $w_1, w_2$  в корпусе;
- $O_{12}$  – количество биграмм в корпусе, начинающихся со слова  $w_1$ ;
- $O_{21}$  – количество биграмм в корпусе, заканчивающиеся словом  $w_2$ ;

- $O_{22}$  – количество биграмм в корпусе, которые не являются биграммой  $w_1, w_2$ .

Таблица 1 – Ранжированные биграммы по частоте встречаемости (столбец  $O_{11}$  по убыванию)

word1	word2	O11	O12	O21	O22
gradient	boosting	58	15	110	155917
of	boosting	13	5388	155	150544
the	boosting	9	12389	159	143543
regression	boosting	8	867	160	155065
to	boosting	6	3533	162	152399
in	boosting	5	3385	163	152547
that	boosting	5	1873	163	154059
why	boosting	3	72	165	155860
but	boosting	3	699	165	155233
and	boosting	3	3255	165	152677
tree	boosting	2	235	166	155697
forests	boosting	2	202	166	155730
fitted	boosting	2	598	166	155334
other	boosting	2	259	166	155673
does	boosting	2	162	166	155770
for	boosting	2	2785	166	153147
or	boosting	2	624	166	155308
on	boosting	2	870	166	155062
stochastic	boosting	1	51	167	155881
class	boosting	1	264	167	155668
help	boosting	1	84	167	155848
moreover	boosting	1	38	167	155894
first	boosting	1	168	167	155764
by	boosting	1	777	167	155155
known	boosting	1	40	167	155892
make	boosting	1	151	167	155781
traditional	boosting	1	12	167	155920
from	boosting	1	902	167	155030
size	boosting	1	75	167	155857
probabilities	boosting	1	60	167	155872
quantile	boosting	1	81	167	155851
example	boosting	1	339	167	155593
usual	boosting	1	94	167	155838
procedure	boosting	1	147	167	155785
conclusions	boosting	1	24	167	155908
perspective	boosting	1	54	167	155878
third	boosting	1	49	167	155883
than	boosting	1	302	167	155630

colinearity	boosting	1	0	167	155932
even	boosting	1	166	167	155766
chapter	boosting	1	78	167	155854
when	boosting	1	476	167	155456
recent	boosting	1	32	167	155900
new	boosting	1	227	167	155705
sparse	boosting	1	8	167	155924
learners	boosting	1	5	167	155927
links	boosting	1	13	167	155919
well	boosting	1	183	167	155749
important	boosting	1	236	167	155696
iteration	boosting	1	27	167	155905
index	boosting	1	25	167	155907
if	boosting	1	568	167	155364
places	boosting	1	4	167	155928
all	boosting	1	420	167	155512
alpha	boosting	1	7	167	155925
called	boosting	1	112	167	155820
bagging	boosting	1	151	167	155781

По результатам ранжирования биграмм по частоте встречаемости можно сделать вывод, что самой часто встречающейся биграммой является биграмма “gradient, boosting”. Это указывает на то, что в анализируемом тексте часто обсуждаются темы, связанные с техникой машинного обучения для задач классификации и регрессии. Биграмму “regression, boosting” не берем в расчет, по крайней мере сейчас, потому что частота появления этой биграммы относительно частот появления каждого её слова в отдельности мизерно.

Устойчивость коллокации не всегда определяет высокая частота встречаемости биграммы. В таблице на лидирующих позициях мы можем заметить биграммы, содержащие в себе союзы и предлоги, которые не всегда можно назвать коллокациями, ведь такие комбинации в большинстве случаев не образуют устойчивого смыслового сочетания.

Следует отметить, что частотный анализ не сможет адекватно определить потенциальные коллокации, когда все биграммы имеют одинаковые частоты. Ранжирование в таких случаях не имеет смысла.

## 2. Проранжируем биграммы, отобранные в п. 1, в соответствие с критериями.

Используем **t-критерий** проверки равенства вероятностей для поиска потенциальных коллокаций. Для каждой отобранной биграммы вычислим статистику:

$$t = \frac{\bar{x} - \mu}{\sqrt{s^2/N}},$$

$\bar{x} = C(w_1, w_2)/N = O_{11}/N$  – вероятность появления биграммы;

$\mu = C(w_1)C(w_2)/N^2 = (O_{11} + O_{12})(O_{11} + O_{21})/N^2$  – среднее при условии справедливости гипотезы, в которой вероятность совстречаемости двух слов равна произведению вероятности каждого слова в отдельности;

$s^2 = \bar{x}(1 - \bar{x})$  – дисперсия для биномиального распределения;

$N$  – общее число биграмм, которое можно определить как сумма всех абсолютных частот из таблицы сопряженности.

Данная статистика используется для определения, является ли разница между наблюдаемой частотой совместного вхождения слов  $w_1$  и  $w_2$  и ожидаемой частотой статистически значимой. Сразу сравним ранжированные статистики с критическим значением – квантилем распределения Стьюдента с  $(N - 1)$  степенью свободы уровня  $(1 - \alpha/2)$ . Уровень значимости был взят равным 0.005.

Таблица 2 – Ранжированные биграммы по значению t-статистики

word1	word2	t_stat	hypothesis	Квантиль
gradient	boosting	7,606870336	Отвергается	2,80707
regression	boosting	2,495548418	Не отвергается	
of	boosting	1,993471545	Не отвергается	
why	boosting	1,68546474	Не отвергается	
that	boosting	1,332196435	Не отвергается	
but	boosting	1,29586607	Не отвергается	
does	boosting	1,28941589	Не отвергается	
forests	boosting	1,258975224	Не отвергается	
tree	boosting	1,233861674	Не отвергается	
other	boosting	1,215597274	Не отвергается	

colinearity	boosting	0,998926966	Не отвергается	
places	boosting	0,99462202	Не отвергается	
learners	boosting	0,993545783	Не отвергается	
alpha	boosting	0,99139331	Не отвергается	
sparse	boosting	0,990317073	Не отвергается	
traditional	boosting	0,986012127	Не отвергается	
links	boosting	0,98493589	Не отвергается	
conclusions	boosting	0,973097287	Не отвергается	
index	boosting	0,972021051	Не отвергается	
iteration	boosting	0,969868577	Не отвергается	
recent	boosting	0,964487394	Не отвергается	
moreover	boosting	0,958029974	Не отвергается	
fitted	boosting	0,957612628	Не отвергается	
known	boosting	0,955877501	Не отвергается	
third	boosting	0,946191372	Не отвергается	
stochastic	boosting	0,944038898	Не отвергается	
perspective	boosting	0,940810188	Не отвергается	
or	boosting	0,937826194	Не отвергается	
probabilities	boosting	0,934352769	Не отвергается	
size	boosting	0,918209219	Не отвергается	
chapter	boosting	0,914980509	Не отвергается	
quantile	boosting	0,911751799	Не отвергается	
help	boosting	0,908523089	Не отвергается	
usual	boosting	0,897760723	Не отвергается	
to	boosting	0,89457524	Не отвергается	
called	boosting	0,878388464	Не отвергается	
procedure	boosting	0,840720182	Не отвергается	
make	boosting	0,836415235	Не отвергается	
bagging	boosting	0,836415235	Не отвергается	
even	boosting	0,820271686	Не отвергается	
first	boosting	0,818119212	Не отвергается	
well	boosting	0,801975663	Не отвергается	
new	boosting	0,754621251	Не отвергается	
on	boosting	0,750616097	Не отвергается	
important	boosting	0,744935122	Не отвергается	
class	boosting	0,714800496	Не отвергается	
than	boosting	0,673903504	Не отвергается	
example	boosting	0,634082749	Не отвергается	
in	boosting	0,604449939	Не отвергается	
all	boosting	0,546907581	Не отвергается	
when	boosting	0,48663833	Не отвергается	
if	boosting	0,38762456	Не отвергается	
by	boosting	0,162691104	Не отвергается	
from	boosting	0,028161525	Не отвергается	
and	boosting	-0,292354345	Не отвергается	
for	boosting	-0,706730803	Не отвергается	

the	boosting	-1,44775474	Не отвергается	
-----	----------	-------------	----------------	--

Данный критерий интуитивно понятен. Однако проблем может доставить частое отклонение нулевой гипотезы, чего можно миновать, варьируя уровень значимости. t-критерий наиболее полезен в качестве ранжировщика коллокаций.

Один из самых важных минусов t-критерия в том, что он основан на предположении о нормальности распределения данных. Однако в реальности многие наборы данных не следуют нормальному распределению. Например, в случае анализа текста, некоторые слова могут встречаться очень часто, в то время как большинство слов встречаются редко, что приводит к скошенному распределению частот.

Найдем **оценки точечной взаимной информации**. По определению, данную оценку можно интерпретировать как объем информации о встречаемости слова  $w_1$ , получаемой от появления слова  $w_2$ . Для каждой отобранной биграммы она вычисляется по следующей формуле:

$$\widehat{PMI} = \log_2 \frac{\frac{C(w_1, w_2)}{N}}{\frac{C(w_1)}{N} * \frac{C(w_2)}{N}} = \log_2 \frac{N * C(w_1, w_2)}{C(w_1)C(w_2)} = \frac{N * O_{11}}{(O_{11} + O_{12})(O_{11} + O_{21})};$$

Здесь мы сравниваем вероятности совместного появления от произведения вероятностей появления каждого слова в отдельности. В случае независимости слов, вероятности будут равными и логарифм будет равен 0.

Таблица 3 – Ранжированные биграммы по значению оценки точечной взаимной информации

word1	word2	PMI
colinearity	boosting	9,859793589
gradient	boosting	9,527950025
places	boosting	7,537865494
learners	boosting	7,274831088
alpha	boosting	6,859793589
sparse	boosting	6,689868588
traditional	boosting	6,159353871



links	boosting	6,052438667
why	boosting	5,215937399
conclusions	boosting	5,215937399
index	boosting	5,159353871
iteration	boosting	5,052438667
recent	boosting	4,81539947
moreover	boosting	4,57439137
known	boosting	4,502241584
third	boosting	4,215937399
stochastic	boosting	4,159353871
perspective	boosting	4,078433875
probabilities	boosting	3,929056251
size	boosting	3,611866076
chapter	boosting	3,556012841
does	boosting	3,502241584
quantile	boosting	3,502241584
help	boosting	3,450402653
usual	boosting	3,289937981
forests	boosting	3,187368247
regression	boosting	3,086654382
called	boosting	3,039614627
tree	boosting	2,97105034
other	boosting	2,831887592
procedure	boosting	2,650340223
make	boosting	2,611866076
bagging	boosting	2,611866076
even	boosting	2,476089296
first	boosting	2,458914153
well	boosting	2,336231633
new	boosting	2,026903575
but	boosting	1,989428869
important	boosting	1,97105034
class	boosting	1,80994504
fitted	boosting	1,630974898
than	boosting	1,616619606
or	boosting	1,569774742
example	boosting	1,450402653
that	boosting	1,306740336
of	boosting	1,161222474
all	boosting	1,142117166
on	boosting	1,091609264
when	boosting	0,961948133
if	boosting	0,707508747
to	boosting	0,655630043
in	boosting	0,454652126
by	boosting	0,256167244

from	boosting	0,041211411
and	boosting	-0,225014799
the	boosting	-0,568101198
for	boosting	-0,584703698

Данный способ оценивания биграмм особенно чувствителен к неточным оценкам вероятностей, возникающим из-за разреженности данных. Часто критерий хи квадрат позволяет найти более подходящие пары слов.

Найдем **оценки средней взаимной информации**.

$$\widehat{MI} = \sum_{i=1}^2 \sum_{j=1}^2 \frac{1}{N} O_{ij} \log_2 \frac{N * O_{ij}}{(O_{i1} + O_{i2})(O_{1j} + O_{2j})}$$

Оценка средней взаимной информации использует все абсолютные частоты из таблицы сопряженности, в отличие от оценки  $\widehat{PMI}$ , что делает её мерой взаимосвязи, аналогичной статистике хи квадрат.

Таблица 4 – Ранжированные биграммы по значению оценки средней взаимной информации

word1	word2	MI
gradient	boosting	0,003426315
regression	boosting	9,46184E-05
why	boosting	7,40306E-05
colinearity	boosting	6,31908E-05
places	boosting	4,01065E-05
learners	boosting	3,82555E-05
alpha	boosting	3,54029E-05
sparse	boosting	3,42545E-05
of	boosting	3,18209E-05
traditional	boosting	3,07268E-05
links	boosting	3,00251E-05
does	boosting	2,82049E-05
conclusions	boosting	2,46243E-05
forests	boosting	2,45422E-05
index	boosting	2,42644E-05
iteration	boosting	2,35863E-05
recent	boosting	2,20917E-05
tree	boosting	2,20829E-05

moreover	boosting	2,05851E-05
other	boosting	2,05291E-05
known	boosting	2,01368E-05
third	boosting	1,83712E-05
stochastic	boosting	1,80249E-05
but	boosting	1,76631E-05
perspective	boosting	1,75313E-05
probabilities	boosting	1,66254E-05
size	boosting	1,47268E-05
that	boosting	1,45958E-05
chapter	boosting	1,43963E-05
quantile	boosting	1,40794E-05
help	boosting	1,3775E-05
usual	boosting	1,28403E-05
called	boosting	1,1407E-05
procedure	boosting	9,25011E-06
make	boosting	9,04243E-06
bagging	boosting	9,04243E-06
fitted	boosting	8,44529E-06
even	boosting	8,31842E-06
first	boosting	8,22787E-06
the	boosting	7,9518E-06
or	boosting	7,91657E-06
well	boosting	7,58827E-06
new	boosting	6,03766E-06
important	boosting	5,76826E-06
to	boosting	5,09111E-06
class	boosting	5,01157E-06
on	boosting	4,21254E-06
than	boosting	4,14752E-06
example	boosting	3,44783E-06
all	boosting	2,27356E-06
in	boosting	2,12553E-06
for	boosting	1,77536E-06
when	boosting	1,67367E-06
if	boosting	9,55323E-07
and	boosting	3,63044E-07
by	boosting	1,3833E-07
from	boosting	3,76113E-09

**3. Для анализируемых биграмм зададим истинные значения переменной класса: 1 – биграмма является коллокацией (устойчивым словосочетанием), 0 – иначе.**

**Сразу построим ROC-кривые для оценки качества классификации биграмм как коллокаций/не коллокаций с помощью критериев.**

На основе частотного анализа, с помощью  $t$ -критерия и средней взаимной информации выделена одна биграмма, которую можно считать коллокацией: **gradient, boosting**.

Эта биграмма имеет высокую частоту встречаемости, значимую  $t$ -статистику и оценку взаимной информации. Она значительно выделяется среди остальных биграмм своей высокой долей вхождения относительно вхождения каждого слова в отдельности.

Если проанализировать ранжирование биграмм на основе  $t$ -критерия и средней взаимной информации, то дополнительно к найденной биграмме можно выделить биграмму **regression, boosting**.

Используя знания предметной области и глоссарий (в конце учебника), можно также выделить биграммы **index, boosting** и **colinearity, boosting**. Ещё вторую биграмму выделяет показатель точечной взаимной информации (однако к данному показателю надо относиться с осторожностью, ведь он чувствителен к разреженным данным).

Зададим для отобранных коллокаций значение переменной класса, равное 1. Для остальных анализируемых биграмм – 0.

Перейдем к построению ROC-кривой. Это график, позволяющий оценить качество бинарной классификации. По вертикальной оси данного графика располагается чувствительность  $TPR$ , а по горизонтальной – частота ложноположительных результатов  $FPR = 1 - TNR$ .

Рассмотрим алгоритм нахождения  $TPR[i]$  и  $FPR[i]$ , необходимых для построения графика, при использовании  $t$  - статистики:

- 1) Формирование исходных данных: массива полученных  $t$  - статистик и массива истинных значений переменной класса.
- 2) Формирование вектора значений  $t$  - уникальных упорядоченных по возрастанию значений  $t$  – статистик.

3) Цикл по всем значениям вектора  $t$ . Для каждого  $t[i]$ :

- классифицировать все объекты обучающей выборки по правилу: если  $t$ -статистика  $> t[i]$ , то положительный класс, иначе – отрицательный;
- на основе предсказанных классов построить таблицу неточностей;
- используя таблицу неточностей, рассчитать и сохранить  $TPR[i]$  и  $FPR[i]$ .

4) По значениям  $TPR$  и  $FPR$  построить ROC-кривую.

Матрица ошибок (матрица неточностей) — это таблица, которая позволяет визуализировать эффективность алгоритма классификации путем сравнения прогнозируемого значения переменной класса с ее фактическим значением. Столбцы матрицы представляют наблюдения в прогнозируемом классе, а строки — наблюдения в фактическом классе.

	Предсказано $\oplus$	Предсказано $\ominus$	Итого
Фактически $\oplus$	$TP$	$FN$	$TP + FN$
Фактически $\ominus$	$FP$	$TN$	$FP + TN$
Итого	$TP + FP$	$FN + TN$	$TP + FP + FN + TN$

- $TP$  – истинно положительные результаты;
- $TN$  – истинно отрицательные результаты;
- $FN$  - ложноотрицательные результаты;
- $FP$  - ложноположительные результаты.

Благодаря матрице неточностей можно вычислить ряд показателей, однако рассмотрим только нужные для построения ROC-кривой:

- Чувствительность. Это доля истинно положительных результатов среди всех действительно положительных случаев. Она вычисляется как  $TPR = TP / (TP + FN)$ ;

- Специфичность. Это доля истинно отрицательных результатов среди всех действительно отрицательных случаев. Она вычисляется как  $TNR = TN / (TN + FP)$ ;
- Частота ложноположительных результатов:  $FPR = 1 - TNR$ .




Рисунок 1 – ROC-кривая для бинарного классификатора, использующего t-критерий

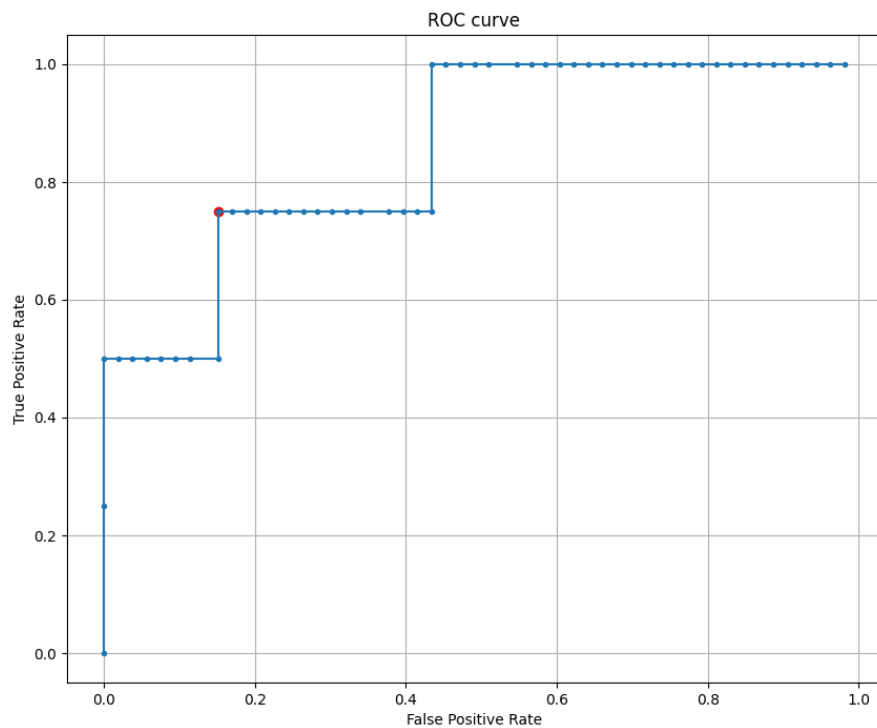


Рисунок 2 – ROC-кривая для бинарного классификатора, использующего показатель точечной взаимной информации




Рисунок 3 – ROC-кривая для бинарного классификатора, использующего показатель средней взаимной информации

Красная точка на графиках - оптимальное пороговое значение  $t^*$ . Она определялась по правилу максимизации специфичности и чувствительности классификатора. Для графиков оптимальная точка соответственно: [0.28302, 1.0], [0.15094, 0.75], [0.20755, 1.0].

Оптимальный порог для t-критерия и критерия максимального правдоподобия определялся как значение  $t^*$ , соответствующее оптимальной точке. Для t-критерия оптимальный порог - 0.84072, для точечной взаимной информации - 1.14212, для средней взаимной информации - 7.58827.

**4. Сравним критерии по качеству классификации на основе показателя AUC (площади под ROC-кривой). Сделаем выводы.**

Показатель AUC – это площадь под ROC-кривой. Чем выше показатель AUC, тем лучше качество классификатора. Если значение  $AUC=0.5$  - непригодность выбранного метода классификации (соответствует случайному гаданию).

AUC для первой ROC-кривой - 0.87264.

AUC для второй ROC-кривой - 0.83491.

AUC для третьей ROC-кривой - 0.92453.

Значения AUC для критериев довольно высоки, что указывает на хорошее качество всех классификаторов. Однако классификатор, основанный на средней взаимной информации, имеет наибольшее значение AUC. Это указывает на то, что он эффективнее всех предсказывает то, является ли биграмма коллокацией или нет.